

Projeto de Business Intelligence para Gestão de Fundos de Investimento

Universidade Federal do Espírito Santo - Centro Tecnológico

Departamento de Informática

Disciplina: INF17411 - Business Intelligence e Gestão Baseada em Dados

Professora: Camila Zacché de Aguiar

Período: 2026/1

Local: Vitória - ES

Resumo

Este relatório apresenta a concepção, a modelagem e a implementação de uma solução de Business Intelligence aplicada à gestão de fundos de investimento. O projeto integra uma fonte interna simulada, composta por clientes, contas, produtos e movimentações, com dados públicos da Comissão de Valores Mobiliários (CVM), do Banco Central do Brasil e do mercado financeiro.

O processamento foi implementado em Python e Pandas segundo uma arquitetura medalhão, com camadas Bronze, Silver e Gold. As informações tratadas são carregadas em um Data Warehouse SQLite, com possibilidade de utilização do PostgreSQL, e consumidas por um dashboard desenvolvido em Streamlit. O resultado é uma base analítica reproduzível, capaz de apoiar análises de patrimônio, rentabilidade, captação, perfil dos investidores, localização, indicadores macroeconômicos e relação entre risco e retorno.

Palavras-chave: Business Intelligence; Data Warehouse; fundos de investimento; arquitetura medalhão; Streamlit; Python.

Sumário

1. Introdução e cenário
2. Objetivos e escopo
3. Fontes de dados
4. Dicionário de dados
5. Questões de análise

6. Modelo multidimensional
 7. Ferramentas utilizadas
 8. Arquitetura e pipeline de dados
 9. Ingestão, tratamento e carga do Data Warehouse
 10. Dashboard
 11. Limitações e trabalhos futuros
 12. Conclusão
 13. Referências
-

1. Introdução e cenário

A Banestes Asset atua na administração fiduciária e na gestão de fundos de investimento distribuídos pelo Banestes S.A., além de realizar a gestão do Fundo de Investimento Imobiliário BCRI11, negociado em bolsa. A atividade de gestão é influenciada tanto pelas características dos clientes e produtos quanto pelo ambiente econômico.

Entre os fatores externos relevantes estão a taxa Selic, a inflação medida pelo IPCA e o comportamento dos índices de mercado. Internamente, a empresa necessita acompanhar clientes, perfis de risco, aplicações, resgates, captação líquida, rentabilidade e patrimônio dos fundos.

O cenário proposto considera que essas informações se encontram dispersas entre sistemas, arquivos e fontes públicas. A solução de BI foi construída para integrar esses dados e disponibilizá-los em uma estrutura única, histórica e apropriada para análise gerencial.

2. Objetivos e escopo

2.1 Objetivo geral

Desenvolver um projeto completo de Business Intelligence para integrar dados internos e públicos relacionados a fundos de investimento, transformando-os em informações analíticas capazes de apoiar decisões sobre desempenho, captação, perfil dos investidores e influência do cenário econômico.

2.2 Objetivos específicos

- Criar uma fonte interna simulada, coerente e reproduzível.
- Obter e explorar fontes públicas relacionadas a fundos e indicadores econômicos.
- Implementar ingestão e tratamento segundo a arquitetura Bronze, Silver e Gold.
- Elaborar um modelo multidimensional com fatos, dimensões e data marts.
- Carregar os dados tratados em um Data Warehouse.
- Definir dez questões gerenciais e as métricas necessárias para respondê-las.
- Disponibilizar as análises em um dashboard Streamlit.

2.3 Recorte adotado

O período configurado compreende janeiro de 2021 a dezembro de 2026. Como 2026 ainda está em andamento, as fontes públicas possuem observações até julho de 2026, enquanto a fonte interna fake e a dimensão de datas abrangem todo o ano configurado. A fonte interna simulada possui:

Entidade	Quantidade
Clientes	900
Contas	1.100
Fundos internos	4
Movimentações	14.000

Para controlar o consumo de memória, a ingestão da CVM seleciona os 80 fundos com maior patrimônio líquido no mês de referência mais recente. No processamento atual foram carregadas 102.590 observações diárias para esses fundos.

3. Fontes de dados

3.1 Fonte interna simulada

A fonte interna foi criada com a biblioteca Faker e complementada com regras de negócio implementadas em Python. A semente 20261 garante que uma execução com a mesma configuração produza dados reproduzíveis.

Foram simuladas quatro entidades:

- **Clientes:** nome, perfil de risco, cidade, estado e datas cadastrais.
- **Contas:** relacionamento com clientes, data de abertura e canal.
- **Fundos:** produto, tipo e faixa de risco.
- **Movimentações:** aplicações e resgates associados a conta, cliente e fundo.

A escolha do fundo é influenciada pelo perfil do investidor. Clientes conservadores possuem maior probabilidade de aplicar em renda fixa, enquanto clientes arrojados têm maior peso em fundos de ações. Essa regra torna a fonte fake adequada para analisar o relacionamento entre perfil e produto.

Quadro 1 - Recorte do cadastro interno de fundos

fund_key	fund_name	fund_type	risk_bucket	ticker
RF_CONSERVADOR	Fundo Renda Fixa Conservador	Renda Fixa	Baixo	
MULTI_MACRO	Fundo Multimercado Macro	Multimercado	Médio	
ACOES_BRASIL	Fundo Ações Brasil	Ações	Alto	
IMOB_FII	Fundo Imobiliário BCRI11	FII	Médio-alto	BCRI11.SA

Quadro 2 - Recorte das movimentações internas

transaction_id	account_id	customer_id	fund_key	transaction_date	transaction_type	amount
1	279	253	IMOB_FII	2022-04-05	Aplicação	6.682,37
2	408	758	RF_CONSERVADOR	2021-11-16	Aplicação	1.229,78
3	833	206	RF_CONSERVADOR	2021-03-05	Resgate	4.853,40

Os nomes presentes nessa fonte são inteiramente sintéticos. Nenhum dado pessoal real foi utilizado.

3.2 Comissão de Valores Mobiliários

Os informes diários de fundos e o cadastro cadastral são obtidos no Portal de Dados Abertos da CVM. Os arquivos mensais contêm dados de patrimônio, valor da cota, aplicações, resgates e quantidade de cotistas.

O perfil exploratório da fonte apresentou:

Característica	Resultado
Período disponível	04/01/2021 a 13/07/2026
Fundos selecionados	80
Observações diárias filtradas	102.590
Fundos com denominação válida na Gold	18
Cadastro CVM	46.808 registros antes do filtro

Quadro 3 - Recorte dos informes da CVM após padronização

fund_cnpj	date	share_value	net_worth	daily_application	daily_redemption	quota_holders
00.083.181/0001-67	2021-01-04	701,02271134	16.337.242.387,53	0,00	0,00	4
00.083.181/0001-67	2021-01-05	701,49668255	16.348.288.224,62	0,00	0,00	4
00.083.181/0001-67	2021-01-06	691,65236546	16.118.867.705,24	0,00	0,00	4

O cadastro de fundos é utilizado para associar o CNPJ à denominação social. Registros sem nome real ou cujo nome contém apenas o próprio CNPJ são excluídos da camada Gold, evitando rótulos inadequados no dashboard.

3.3 Banco Central do Brasil

Os indicadores macroeconômicos são obtidos pela API SGS do Banco Central:

- Série 11: taxa Selic diária.
- Série 433: IPCA mensal.

As séries possuem calendários diferentes e são combinadas por data com junção externa, preservando todas as observações. O conjunto processado possui 1.416 linhas, entre 01/01/2021 e 15/07/2026.

Quadro 4 - Recorte das séries macroeconômicas

date	selic_daily_pct	ipca_monthly_pct	month
2021-01-01		0,25	2021-01-01
2021-01-04	0,007469		2021-01-01
2021-01-05	0,007469		2021-01-01
2021-01-06	0,007469		2021-01-01

3.4 Dados de mercado

O projeto utiliza o yfinance para solicitar os fechamentos ajustados de BCRI11.SA e ^BVSP. A finalidade é calcular retorno mensal, volatilidade e índices acumulados de base 100.

Na exploração registrada durante o desenvolvimento, essa requisição retornou zero linhas. O pipeline e o esquema analítico estão preparados para a fonte, mas uma nova execução bem-sucedida é necessária para preencher a comparação BCRI11 versus Ibovespa antes da captura definitiva do dashboard.

4. Dicionário de dados

O dicionário completo, com tipos, granularidade e descrição de todas as colunas, está disponível em docs/data_dictionary.md. Esta seção apresenta as estruturas centrais das fontes e do modelo analítico.

4.1 Campos da fonte interna

Tabela	Chave ou granularidade	Campos principais
internal_customers	Um cliente por customer_id	customer_name, investor_profile, city, state, birth_date, signup_date
internal_accounts	Uma conta por account_id	customer_id, account_open_date, channel
internal_funds	Um produto por fund_key	fund_name, fund_type, risk_bucket, ticker
internal_transactions	Uma movimentação por transaction_id	account_id, customer_id, fund_key, transaction_date, transaction_type, amount

4.2 Campos das fontes externas

Fonte	Campo original	Significado
CVM	CNPJ_FUNDO / CNPJ_FUNDO_CLASSE	Identificador do fundo ou classe
CVM	DT_COMPTC	Data de competência
CVM	VL_QUOTA	Valor da cota
CVM	VL_PATRIM_LIQ	Patrimônio líquido
CVM	CAPTC_DIA	Aplicação informada no dia
CVM	RESG_DIA	Resgate informado no dia
CVM	NR_COTST	Quantidade de cotistas
BCB	selic_daily_pct	Taxa Selic diária da série SGS 11
BCB	ipca_monthly_pct	IPCA mensal da série SGS 433
Yahoo Finance	close	Fechamento ajustado do ativo
Yahoo Finance	ticker	Identificador BCRI11.SA ou ^BVSP

4.3 Tabelas dimensionais e fatos

Tabela	Granularidade	Finalidade
dim_date	Um registro por dia	Calendário para agrupamentos temporais
dim_customer	Um registro por cliente	Perfil e localização dos investidores
dim_fund	Um registro por fundo interno	Tipo de produto e faixa de risco
fact_transactions	Uma movimentação	Aplicações, resgates e captação líquida
fact_public_fund_monthly	Um fundo público por mês	Patrimônio, fluxo, retorno e volatilidade
fact_macro_monthly	Um registro por mês	Selic e IPCA
fact_market_monthly	Um ativo por mês	Fechamento, retorno e volatilidade

4.4 Data marts do Streamlit

Tabela	Conteúdo analítico
gold_public_funds_monthly	Série mensal e retorno acumulado dos fundos públicos
gold_risk_return	Indicadores consolidados de risco e retorno por fundo
gold_internal_flows_monthly	Aplicações, resgates e captação por fundo e mês
gold_investor_profile_fund_type	Volume por perfil e tipo de fundo
gold_city_investment	Volume e investidores por cidade
gold_macro_funds_monthly	Selic, IPCA, fluxo de renda fixa e retorno dos fundos
gold_market_comparison_monthly	Comparação BCRI11 e Ibovespa

5. Questões de análise

As questões foram definidas para cobrir desempenho, fluxo financeiro, clientes, geografia, ambiente macroeconômico e risco.

Nº	Questão	Visualização adotada	Dimensões e medidas
1	Qual foi a evolução mensal do patrimônio líquido por fundo?	Gráfico de linhas	Mês, fundo e patrimônio líquido
2	Qual fundo teve maior rentabilidade acumulada no período?	Ranking em barras horizontais	Fundo e retorno acumulado
3	Qual foi o volume mensal de aplicações e resgates?	Barras agrupadas	Mês, aplicações e resgates
4	Em quais meses houve maior captação líquida?	Ranking em barras horizontais	Mês e captação líquida
5	Qual perfil de investidor mais aplicou em cada tipo de fundo?	Barras agrupadas	Tipo de fundo, perfil e aplicações
6	Quais cidades concentram maior volume investido?	Ranking em barras horizontais	Cidade, UF e aplicações
7	Existe relação entre Selic e captação em fundos de renda fixa?	Linha e barras com dois eixos	Mês, Selic e captação líquida
8	Existe relação entre IPCA e rentabilidade dos fundos?	Dispersão	IPCA e retorno médio dos fundos
9	Como o BCRI11 se comportou em comparação ao Ibovespa?	Linhas em índice base 100	Mês e índices acumulados
10	Quais fundos tiveram melhor relação entre rentabilidade e risco?	Dispersão com tamanho por patrimônio	Volatilidade, retorno e patrimônio

As análises 7 e 8 permitem observar associação visual e não devem ser interpretadas, isoladamente, como evidência de causalidade.

6. Modelo multidimensional

O modelo segue uma constelação de fatos. O processo interno utiliza dimensões compartilhadas de data, cliente e fundo. Os dados públicos possuem fatos mensais específicos para fundos, macroeconomia e mercado.




Figura 1 - Modelo dimensional do projeto

6.1 Dimensões

- **dim_date:** data, ano, trimestre, mês e primeiro dia do mês.
- **dim_customer:** cliente, perfil do investidor e localização.
- **dim_fund:** fundo interno, tipo e faixa de risco.

6.2 Fatos

- **fact_transactions:** granularidade de uma movimentação, com valores de aplicação, resgate e captação líquida.
- **fact_public_fund_monthly:** granularidade de um fundo público por mês.
- **fact_macro_monthly:** granularidade mensal para Selic e IPCA.

- **fact_market_monthly**: granularidade de um ativo por mês.

6.3 Medidas derivadas

As principais medidas são calculadas da seguinte forma:

```
application_amount = amount, quando transaction_type = "Aplicacao"
redemption_amount  = amount, quando transaction_type = "Resgate"
net_flow_amount     = application_amount - redemption_amount

monthly_return = produto(1 + daily_return) - 1
volatility      = desvio_padrao(daily_return)

return_risk_ratio = accumulated_return / avg_daily_volatility
```

O arquivo-fonte atualizado do modelo encontra-se em docs/dbdiagram.dbml. As chaves do DBML representam o modelo lógico. A carga atual realizada pelo Pandas recria as tabelas sem aplicar fisicamente todas as restrições de chave.

7. Ferramentas utilizadas

Ferramenta	Papel no projeto	Justificativa
Python 3.11+	Linguagem principal	Ecossistema adequado para engenharia e análise de dados
Pandas	Ingestão, limpeza e agregação	Operações tabulares e tratamento de séries temporais
Faker	Geração da fonte interna	Dados sintéticos reproduzíveis sem exposição de dados reais
Requests	Consumo das APIs públicas	Requisições HTTP para CVM e Banco Central
yfinance	Dados de mercado	Interface para cotações do BCRI11 e Ibovespa
NumPy	Cálculos vetorizados	Medidas condicionais e tratamento numérico
SQLAlchemy	Carga e consulta do warehouse	Compatibilidade com SQLite e PostgreSQL
SQLite	Data Warehouse da demonstração	Banco portátil, simples e incluído no repositório de apresentação
PostgreSQL	Alternativa de Data Warehouse	Opção para execução em ambiente de servidor
Streamlit	Dashboard	Construção rápida de aplicação analítica interativa
Plotly	Gráficos	Interatividade, hover, zoom e diferenciação de séries
dbdiagram.io / DBML	Modelo dimensional	Documentação visual das tabelas e relacionamentos
Ruff	Qualidade do código	Formatação e verificação estática

8. Arquitetura e pipeline de dados

O pipeline segue a arquitetura medalhão:

Fontes internas e públicas

|
v

Bronze -> Silver -> Gold -> Data Warehouse -> Streamlit

8.1 Bronze

A camada Bronze preserva os dados brutos:

- data/bronze/internal: CSVs da fonte fake.
- data/bronze/public/cvm: arquivos ZIP e CSV originais da CVM.
- Respostas das APIs são mantidas em memória e encaminhadas ao tratamento.

Essa camada permite rastreabilidade e evita novo download dos arquivos da CVM quando eles já estão disponíveis localmente.

8.2 Silver

A camada Silver contém dados limpos e padronizados:

- conversão de datas e valores numéricos;
- normalização de CNPJ_FUNDO_CLASSE para CNPJ_FUNDO;
- renomeação de colunas para nomes analíticos;
- remoção de registros sem data ou identificador;
- cálculo de retorno diário e captação líquida;
- seleção das colunas necessárias;
- filtro dos fundos de referência.

8.3 Gold

A camada Gold contém:

- dimensões e fatos do modelo multidimensional;
- agregações mensais;
- retornos compostos;
- volatilidade;
- índices de base 100;
- data marts específicos para cada grupo de gráficos.

Os DataFrames Gold são gravados em CSV para auditoria e carregados no Data Warehouse.

8.4 Data Warehouse e apresentação

O Data Warehouse é a fonte oficial do dashboard. O SQLite utilizado na apresentação fica em warehouse/bi_fundos.sqlite. A mesma aplicação aceita PostgreSQL por meio da variável WAREHOUSE_URL.

O Streamlit consulta as tabelas `gold_*` do banco. Os CSVs são utilizados apenas como contingência quando o warehouse não está disponível, situação sinalizada na barra lateral do dashboard.

9. Ingestão, tratamento e carga do Data Warehouse

9.1 Configuração do ambiente

```
python -m venv .venv
..venvScriptsActivate.ps1
pip install -r requirements.txt
```

O arquivo `.env` define a URL do warehouse:

```
WAREHOUSE_URL=sqlite:///warehouse/bi_fundos.sqlite
```

9.2 Geração da fonte interna

O módulo `src/fake_internal.py`:

1. inicializa Faker, Random e NumPy com a mesma semente;
2. gera os clientes e atribui perfis com pesos definidos;
3. gera contas relacionadas aos clientes;
4. seleciona fundos com pesos dependentes do perfil;
5. gera aplicações e resgates com valores de distribuição lognormal;
6. grava os quatro CSVs na camada Bronze.

Trecho representativo:

```
fake = Faker("pt_BR")
Faker.seed(config.seed)
random.seed(config.seed)
np.random.seed(config.seed)
```

9.3 Ingestão da CVM

O módulo `src/sources_public.py` baixa os informes mensais e o cadastro. Antes de concatenar o período inteiro, o pipeline:

1. abre o arquivo mensal mais recente disponível;
2. ordena os fundos por `VL_PATRIM_LIQ`;
3. seleciona os maiores CNPJs;
4. lê somente as colunas necessárias de cada arquivo;
5. filtra cada mês antes da concatenação.

Essa estratégia reduziu o volume carregado e evitou o consumo excessivo de memória observado na primeira versão do pipeline.

9.4 Ingestão do Banco Central e mercado

As séries do Banco Central são consultadas com período inicial e final:

```
fetch_bcb_series(11, "selic_daily_pct", start_date, end_date)
fetch_bcb_series(433, "ipca_monthly_pct", start_date, end_date)
```

As cotações são solicitadas para:

```
["BCRI11.SA", "^BVSP"]
```

9.5 Tratamento Silver

O módulo `src/transform.py` implementa a padronização. Entre as regras aplicadas estão:

- `pd.to_datetime(..., errors="coerce")` para datas;
- `pd.to_numeric(..., errors="coerce")` para medidas;
- cálculo de `date_key` no formato `YYYYMMDD`;
- cálculo de `daily_net_flow`;
- ordenação por fundo e data antes de calcular retornos;
- associação dos nomes do cadastro CVM;
- exclusão de fundos sem denominação válida.

9.6 Transformação Gold

Os fatos públicos são agregados por CNPJ e mês. O retorno mensal é composto a partir dos retornos diários:

```
lambda s: (1 + s.dropna()).prod() - 1
```

Os data marts do Streamlit são construídos em `src/dashboard_marts.py`. Essa etapa combina fatos e dimensões para entregar ao dashboard tabelas no nível exato de cada visualização.

9.7 Carga do Data Warehouse

O módulo `src/load_warehouse.py` cria uma engine SQLAlchemy e carrega todas as tabelas Gold:

```
engine = create_engine(warehouse_url)
with engine.begin() as connection:
    for table_name, df in tables.items():
        df.to_sql(table_name, connection, if_exists="replace", index=False)
```

O uso de transação garante que cada operação de carga seja controlada pela conexão do banco. A opção `replace` torna a execução idempotente para fins de demonstração: uma nova execução substitui a versão anterior das tabelas.

9.8 Execução completa

```
python -m src.pipeline --warehouse sqlite:///warehouse/bi_fundos.sqlite
```

Para reduzir o número de fundos públicos:

```
python -m src.pipeline --max-public-funds 30
```

Para iniciar o dashboard:

```
streamlit run app.py
```

Durante a apresentação, a barra lateral deve indicar:

```
Fonte: Data Warehouse (SQLITE)
```

10. Dashboard

PENDENTE: inserir nesta seção a imagem final do dashboard Streamlit.

O dashboard foi organizado em cinco abas:

1. Visão geral.
2. Fundos e captação.
3. Investidores e geografia.
4. Macro x fundos.
5. Mercado, risco e retorno.

Os gráficos utilizam filtros de período, cores distintas para fundos e ativos, tooltips, zoom e tabelas auxiliares. Os indicadores monetários são apresentados em formato compacto, mantendo o valor completo no texto de ajuda.

11. Limitações e trabalhos futuros

- A fonte interna é sintética e representa um cenário analítico, não o comportamento real dos clientes do Banestes.

- A seleção dos maiores fundos reduz o consumo de memória, mas não representa todo o universo da CVM.
- A relação visual entre variáveis macroeconômicas e fundos indica associação, não causalidade.
- A execução registrada do yfinance não retornou cotações. A coleta deve ser repetida antes da captura final do gráfico BCRI11 versus Ibovespa.
- O processo atual substitui as tabelas do warehouse. Uma evolução futura pode adotar carga incremental, controle de versão e restrições físicas de integridade.
- O PostgreSQL está previsto e suportado, mas a demonstração utiliza SQLite por sua portabilidade.

12. Conclusão

O projeto implementa o ciclo completo solicitado para uma solução de Business Intelligence: definição do escopo, criação de fonte interna, exploração de fontes públicas, modelagem multidimensional, tratamento em arquitetura medalhão, carga em Data Warehouse e construção de dashboard.

A integração entre dados transacionais simulados, informações de fundos da CVM e indicadores do Banco Central permite analisar o desempenho dos fundos sob diferentes perspectivas. A separação em camadas melhora a rastreabilidade, enquanto o Data Warehouse centraliza as informações tratadas e estabelece uma fonte única para o Streamlit.

Além de responder às questões gerenciais propostas, a implementação é reproduzível e pode ser evoluída para PostgreSQL, novas fontes externas, cargas incrementais e análises estatísticas mais aprofundadas.

13. Referências

- BANCO CENTRAL DO BRASIL. Sistema Gerenciador de Séries Temporais - SGS. Disponível em: <https://www3.bcb.gov.br/sgspub/>. Acesso em: 2026.
- COMISSÃO DE VALORES MOBILIÁRIOS. Portal de Dados Abertos da CVM. Disponível em: <https://dados.cvm.gov.br/>. Acesso em: 2026.
- DBML. DBML Syntax. Disponível em: <https://dbml.dbdiagram.io/docs/>. Acesso em: 2026.
- PANDAS. Pandas documentation. Disponível em: <https://pandas.pydata.org/docs/>. Acesso em: 2026.
- PLOTLY. Plotly Python Open Source Graphing Library. Disponível em: <https://plotly.com/python/>. Acesso em: 2026.
- STREAMLIT. Streamlit documentation. Disponível em: <https://docs.streamlit.io/>. Acesso em: 2026.
- YFINANCE. yfinance documentation. Disponível em: <https://ranaroussi.github.io/yfinance/>. Acesso em: 2026.

Artefatos complementares

- docs/data_dictionary.md: dicionário de dados completo.
- docs/dbdiagram.dbml: modelo multidimensional.
- docs/architecture.md: arquitetura técnica.

- `sql/analysis_queries.sql`: consultas correspondentes às dez questões.
- `src/`: código-fonte do pipeline.
- `app.py`: dashboard Streamlit.